

医疗 RAG 证据选择的无泄漏评测、部署差距与生成验证

史语涵 王琦*

(太原理工大学软件学院 山西 晋中 030600)

摘要 针对医疗 RAG 证据选择中私有状态标签可能污染评测的问题, 设置 Public/Private 隔离边界和 B0—D3 诊断条件, 在 27.15 万篇中文医疗文档及 webMedQA、cMedQA2 上开展组件分解、泄漏注入、MMR 对照、Top-K 敏感性与生成盲评。双 Oracle 条件使 DemandCov 提高 0.0229~0.0637; 当前低资源 D3 未形成稳定覆盖优势, MMR-TFIDF 亦未获得显著覆盖增益, K=3、5、7 下主要方向一致。60 题 240 条回答的生成差异经 Holm 校正后均不显著。结果提示, 无泄漏诊断可用于区分 Oracle 空间、一般多样化效应和可部署收益。

关键词 医疗检索增强生成 标签泄漏 Oracle—部署差距 证据选择 需求覆盖 生成验证

中图分类号 TP391.1 文献标志码 A

LEAKAGE-CONTROLLED EVALUATION, DEPLOYMENT GAPS, AND GENERATION VALIDATION FOR MEDICAL RAG EVIDENCE SELECTION

Shi Yuhan Wang Qi*

(College of Software, Taiyuan University of Technology, Jinzhong 030600, Shanxi, China)

Abstract Private query-state and evidence-support labels may enter the inference pipeline of medical retrieval-augmented generation (RAG) systems and inflate evaluation results. To examine this risk, a Public/Private isolation boundary and five diagnostic conditions, B0-D3, were specified. Experiments were conducted on 271,548 Chinese medical documents with webMedQA and cMedQA2, covering component-gap decomposition, controlled leakage injection, an MMR baseline, Top-K sensitivity analysis, and blind human evaluation of generated answers. Under the dual-oracle condition, DemandCov increased by 0.0229-0.0637 across the three evaluation splits. However, the current low-resource D3 configuration did not produce a stable coverage advantage over the reranker baseline. MMR-TFIDF likewise showed no statistically significant coverage improvement, while the main trend remained directionally consistent at K=3, 5, and 7. For generation evaluation, 240 responses from 60 questions under four evidence conditions were independently rated and adjudicated. None of the answer-level differences remained significant after Holm correction. These results indicate that, under the current data, candidate-pool, predictor, and evaluation settings, leakage-controlled diagnosis can help distinguish oracle reference space, generic diversification effects, and deployable gains. The findings should be interpreted as diagnostic evidence rather than proof of equivalence or universal ineffectiveness.

Keywords Medical retrieval-augmented generation Label leakage Oracle-to-deployment gap Evidence selection Demand coverage Generation validation

0 引言

检索增强生成(Retrieval-Augmented Generation, RAG)通过在回答前检索外部证据,缓解大语言模型知识滞后和无依据生成问题^[1]。医疗问答通常同时包含

症状病程、病因诊断、治疗用药、特殊人群和风险处置等需求。若仅按单篇相关性排序, Top-K 证据容易集中于同一语义侧面, 遗漏风险提示、用药限制或就医建议。医疗 RAG 的可靠性因此不仅取决于召回相关文档, 还取决于证据集合能否覆盖关键需求, 并被

生成模型正确使用^{[2][3][4][5]}。

状态感知证据选择需要查询需求、证据支持需求和风险标签,但这些字段往往由人工标注获得。若私有标签被写入候选 metadata、部署特征或预测缺失时的 fallback,系统就可能间接读取 Gold 并产生虚高结果。机器学习中的数据泄漏会造成过度乐观且难以复现的结论^[6];RAG 又由检索、预测、选择和生成多个模块串联,仅看最终均值很难区分候选覆盖不足、选择器目标失配和标签污染。

现有 RAGAS、ARES、RAGChecker 和 RAGTruth 分别评价上下文相关性、答案忠实性、模块错误和幻觉^{[7][8][9][10]},RGB、MedRAG 及 MIRAGE 进一步强调噪声、拒答和医疗场景的系统评测^{[2][3][11]}。然而,“Oracle 标签能够产生多大参考收益”“该收益能否被预测信号恢复”“覆盖提升是否真正改善生成答案”仍常被混合在同一端到端分数中。

为此,本文设置 B0—D3 五个诊断条件,分解 Oracle 参考收益、查询预测损失、证据预测损失和部署恢复率,并开展渐进泄漏注入、MMR-TFIDF 对照、Top-K 敏感性及 60 题 240 条答案的盲评。本文不提出新的证据选择算法,而以中文医疗 RAG 为案例,验证无泄漏评测流程的可复算性与组件定位能力。

1 相关工作

1.1 检索融合与集合选择

BM25 基于概率相关框架进行稀疏匹配^[12],DPR 利用双编码器获得语义召回^[13],RRF 可在不同分数尺度下融合多个排序列表^[14],Sentence-BERT 支持通用句向量表示^[15]。候选集合除相关性外还涉及互补性,MMR 通过相关性与新颖性加权降低文档冗余^[16]。MMR 不依赖医疗需求标签,优化的是文档间差异;DemandCov 则评价证据集合是否覆盖问题所需的信息类别,二者相关但不等价。国内研究从信息检索流程总结知识库问答技术^[17],并探索滑动窗口分块对 RAG 性能的影响^[18]。

1.2 RAG 评价、覆盖与标签泄漏

RAGAS、ARES 与 RAGChecker 强调从检索上下文、答案忠实性和细粒度错误角度诊断 RAG^{[7][8][9]};RAGTruth 构建了面向无依据生成的人工语料^[10];Sub-Question Coverage 关注复杂问题中重要子问题是否被覆盖^[4]。这些工作说明相关性、覆盖和 Faithfulness 属于不同层次。本文进一步关注评价标签经特征工程或回退逻辑进入推理路径的污染,并以行为不变性而

非口头声明验证无泄漏边界。

1.3 医疗 RAG 与中文医疗数据

MedRAG 系统比较多种医学语料、检索器和生成模型组合^[2];MIRAGE 分析噪声敏感、上下文接受和误读等检索—生成耦合问题^[3];RAG² 以医学推理依据引导检索^[5]。webMedQA 来自真实中文在线医疗咨询^[19],cMedQA2 用于中文医疗问题—答案匹配^[20]。与上述面向系统组合、整体评价或推理引导的研究不同,本文仅聚焦私有状态标签进入证据选择路径造成的评测污染,以及 Oracle 条件与可部署条件被混用的问题。

2 任务与无泄漏评测方案

2.1 需求覆盖任务与指标

设问题 q 的真实需求集合为 G_q ,候选文档 d 针对 q 的支持需求集合为 $G_{q,d}$,选择器从候选池 C_q 中选取不超过 $K=5$ 篇文档得到 S_q 。定义

$$\text{DemandCov}@5(q) = \frac{\left| G_q \cap \bigcup_{d \in S_q} G_{q,d} \right|}{|G_q|} \quad (1)$$

G_q 为空的问题不参与该指标。NDCG@10 按当前候选池的 relevance 标签构造理想排序^[21]。DemandCov 衡量信息侧面的覆盖,NDCG 衡量高相关证据的位置,二者不可替代。15 类细粒度状态与 6 类医疗需求之间的映射关系见表 1。

表 1 15 类状态到 6 类医疗需求的映射

需求	细粒度状态
D01 症状与病程	symptom / duration / severity
D02 病因与诊断	request_cause / request_diagnosis
D03 治疗与用药	treatment / medication / medication risk
D04 人群与病史	population / history / special population
D05 照护与急症	request_care / risk_emergency
D06 心理与安全	risk_mental_health

细粒度状态用于标注问题和证据语义,类需求由 15 类状态合并,用于集合覆盖计算并降低稀有类别的评价方差;risk_medication 归入 D03。该分类属于任

务型操作分类,不是 ICD 或 SNOMED CT 临床本体。D3 仅接收预测后的 6 类需求,不读取细粒度 Gold 状态。

2.2 Public/Private 物理隔离

PublicQuery 仅保存 qid 和 question ; PublicCandidate 仅保存 qid、doc_id、title、content 和 reranker_score 。 QueryGold 保存 query_states 、 query_demands 及关键需求, EvidenceGold 保存 supported_states 、 supported_demands 、 relevance 和 risk_types。Public Runtime 禁止导入 Private Evaluation 模块, D3 只能读取公开对象、冻结模型和预测结果; Gold 在 selected_doc_ids 生成后才进入指标计算。




图1 公开推理数据与私有评价标签的物理隔离流程

如图 1 所示,终检分别隐藏 Query Gold、隐藏 Evidence Gold 并替换伪 Gold, formal_train 、 internal_blind 和 cMedQA2_external 的 D3 逐 qid Top-5 均保持不变;静态边界检查亦未发现 Gold 回退。该设计把“代码中未显式调用 Gold”转化为可执行的字段边界和行为不变性。

2.3 B0—D3 条件分解

为区分 Oracle 参考空间、组件预测损失与可部署收益,设置 B0 及 D0—D3 五个诊断条件,具体定义见表 2。

表2 B0 与 D0—D3 条件定义

条件	Query 需求	Evidence 支持	用途
B0	不使用	不使用	reranker Top-5 基线
D0	Gold	Gold	双 Oracle 参考
D1	Predicted	Gold	隔离查询预测损失
D2	Gold	Predicted	隔离证据预测损失
D3	Predicted	Predicted	可部署条件

定义

$$\text{OracleGain} = D0 - B0$$

$$\text{QueryLoss} = D0 - D1$$

$$\text{EvidenceLoss} = D0 - D2$$

$$\text{InteractionLoss} = D1 + D2 - D0 - D3$$

$$\text{QueryRecovery} = \frac{D1 - B0}{D0 - B0}$$

$$\text{EvidenceRecovery} = \frac{D2 - B0}{D0 - B0}$$

$$\text{EndToEndRecovery} = \frac{D3 - B0}{D0 - B0}$$

D0、D1 和 D2 仅为诊断条件,不作为可部署方法宣传;恢复率允许为负,表示预测信号使结果低于 B0。

3 数据、标注与实验设置

3.1 语料、划分与候选池

清洗后的公开语料共 271548 篇中文医疗文档。 formal_train 用于 Q1/E2 训练和 qid 级 5 折 OOF 评价, formal_dev 用于尺度诊断与参数冻结,不计入最终主结果; internal_blind 和 cMedQA2_external 仅用于冻结配置后的最终评价。候选池由 BM25 Top-10、 BAAI/bge-small-zh-v1.5 稠密检索 Top-10、 RRF 融合 Top-10 和 BAAI/bge-reranker-v2-m3 重排序 Top-10 合并去重,每题最多 15 篇,不使用 Gold 构造候选。各数据划分、样本规模及候选池设置见表 3。

表3 数据划分与候选池规模

划分	来源	规模 (qid/pair)	每题 候选	用途
formal_train	webMe dQA	200/3000	15	训练/OOF
formal_dev	webMe dQA	100/1500	15	开发/冻结
internal_blin d	webMe dQA	200/3000	15	内部保留

划分	来源	规模 (qid/pair)	每题 候选	用途
cMedQA2_external	cMedQA2	142/2124	9~15	外部验证

3.2 标注、预测器与选择器

问题级标注包括 query_states；证据级标注包括 relevance_0_1_2、supported_states 和 risk_types。计算机专业项目成员 A 与临床医学本科生 B 依据统一指南独立标注证据对，中医学专业本科生复核分歧。三个主评测划分共 542 个 qid、8124 个问题—证据对，单个证据对需同时判断相关性、支持需求和风险类型，因此其人工成本不能与自动构造的大规模问答基准直接类比。internal_blind 和 cMedQA2_external 的 relevance 一致率分别为 92.6%和 94.4%，Cohen’s κ 为 0.885 和 0.911。问题级规则在标注前共同梳理，其 100%一致仅作为规则标准化后的确认结果。团队不含执业医师，Gold 主要服务于预定义信息需求覆盖评价，不能替代临床诊断、指南一致性判断或高风险用药决策。

B0 为冻结 reranker 分数排序后的 Top-K。Q1 和 E2 均采用字符 2~4 gram TF-IDF 与 One-vs-Rest 逻辑回归，class_weight=balanced，阈值 0.5；E2 输入为 “[QUERY] question [DOCUMENT] content”。选择该配置是因为训练 qid 有限、特征与参数便于审计，且可在每个 OOF 折内独立拟合，作为低资源诊断基线而非最强预测器。formal_train 按 qid 分组进行 5 折 OOF，TF-IDF 在每折独立拟合。Version B 参数固定为 $\alpha=0.1$ 、 $\beta=0.2$ 、 $\gamma=0.2$ 、 $\delta=0.05$ 、 $\eta=0$ 。为提供非状态化多样性对照，在同一候选池上实现 MMR-TFIDF：相关性取 qid 内归一化 reranker 分数，相似度取候选文档字符 2~4 gram TF-IDF 余弦； λ 仅在 formal_dev 的 {0.5,0.6,0.7,0.8,0.9} 中按 DemandCov 优先规则选择，最终冻结为 0.6。由于现有 dense 向量对候选 doc_id 覆盖不足，该方法仅作为代理 MMR 基线。Top-K 敏感性只改变 $K \in \{3,5,7\}$ ，其余模型、权重和阈值均保持冻结。

3.3 生成端盲评与统计

从 60 个 qid 构造 B0、D0、D3-TFIDF 和 D3-E2-RoBERTa 四种证据条件，统一调用 deepseek-chat 生成 240 条答案，temperature=0。D3-E2-RoBERTa 仅替换 E2，Q1 保持 TF-IDF 配置。盲评文件采用 opaque answer_id 随机排序，不显示条件名称、方法顺序和 doc_id；评价者需看到问题、证

据与答案以判断 Faithfulness，因此为条件盲法。A/B 独立评价 6 项指标，44 条分歧由 C 仲裁，正式分析使用仲裁分数。生成端人工评价指标、量表及判定重点见表 4。

表 4 生成端人工评价指标与判定重点

指标	量表	判定重点
Faithfulness	0/1/2	主要事实与建议是否由给定证据支持
Answer relevance	0/1/2	是否直接回应用户问题
Demand completeness	0/1/2	是否覆盖问题中的主要需求
Overall utility	0/1/2	综合正确性、完整性与可用性
Unsupported claim	0/1	是否出现明确无证据主张
Critical risk omission	0/1	是否遗漏必要风险提示或就医建议

检索主结果采用 qid 级配对 Bootstrap，重采样 10000 次^[22]。生成端 0/1/2 指标以排除零差的 exact sign test 为主检验，0/1 指标采用 McNemar exact test；置信区间使用 qid 级配对 percentile Bootstrap(10000 次，seed=42)，PRIMARY 与 DIAGNOSTIC 家族分别进行 Holm 校正。240/240 条 Answer relevance 均为 2、方差为 0，标记为天花板效应并不参与检验。

4 实验结果

4.1 需求覆盖与相关性排序

B0 及 D0—D3 在三个评测划分上的 DemandCov@5 与 NDCG@10 结果见表 5。

表 5 三划分 DemandCov@5/NDCG@10 主结果

条件	formal	internal	external
B0	0.8762/0.6413	0.9183/0.5338	0.9630/0.5166
D0	0.9398/0.6012	0.9819/0.4988	0.9859/0.4849
D1	0.9219/0.6065	0.9537/0.5094	0.9836/0.4961
D2	0.8702/0.6319	0.9282/0.5109	0.9765/0.5074
D3	0.8745/0.6293	0.9216/0.5075	0.9730/0.4954

D0 相对 B0 的 DemandCov@5 在三个划分提高 0.0636、0.0637 和 0.0229，D1 亦显著高于 B0；D2 和 D3 与 B0 的覆盖差异均不显著。D3 在 formal_train、internal_blind 和 external 的覆盖差值分别为−0.0017、0.0033 和 0.0100。相关性排序方面，D3 相对 B0 的

NDCG@10 分别下降 0.0120、0.0264 和 0.0211；在补充比较的 Holm 校正后, formal 和 internal 仍显著 ($p=0.0220$ 和 0.0204), external 不显著。结果表明, 当前预测配置未恢复稳定覆盖收益, 并在部分划分产生可检测的排序代价。DemandCov@5 的关键配对 Bootstrap 结果见表 6。

表 6 DemandCov@5 关键配对 Bootstrap 结果

划分	比较	均值差	95% CI	p
formal	D0-B0	0.0636	[0.0445,0.0845]	0.0002
formal	D3-B0	-0.0017	[-0.0204,0.0145]	0.8799
internal	D0-B0	0.0637	[0.0418,0.0880]	0.0002
internal	D3-B0	0.0033	[-0.0127,0.0195]	0.6599
external	D0-B0	0.0229	[0.0070,0.0434]	0.0016
external	D3-B0	0.0100	[-0.0070,0.0311]	0.3092

4.2 Oracle—部署差距

由 2.3 节定义的分解公式, 可得各划分的组件损失与恢复率, 结果如表 7 所示。

表 7 Oracle—部署差距及恢复率分解

指标	formal	internal	external
OracleGain	0.0636	0.0637	0.0229
QueryLoss	0.0179	0.0282	0.0023
EvidenceLoss	0.0697	0.0537	0.0094
Interaction Loss	-0.0222	-0.0216	0.0012
Q 恢复	71.8%	55.6%	89.7%
E 恢复	-9.6%	15.7%	59.0%
端到端恢复	-2.8%	5.2%	43.6%

EvidenceLoss 在三个划分均大于 QueryLoss, 是当前部署差距的主要来源。formal 和 internal 的 InteractionLoss 为负, 表示两类误差在贪心选择中部分抵消; external 为 0.0012。external 端到端恢复率虽为 43.6%, 但 OracleGain 绝对值仅 0.0229 且 D3 提升不显著, 恢复率不能脱离 Oracle 空间和置信区间单独解释。

4.3 可控标签泄漏注入

六个端点在逐 qid Top-5 层面全部闭合, 1050 行

结果重放一致。query-only 由 D3 过渡至 D2 时, DemandCov/NDCG 由 0.8745/0.6293 变为 0.8702/0.6319; evidence-only 至 D1 时变为 0.9219/0.6065; joint 至 D0 时变为 0.9398/0.6012。中间比例存在 seed 波动。结果提示, 证据侧 Gold 暴露更易提高覆盖, 同时降低排序质量; 该趋势仅限于 formal_train OOF 分析。六个确定性泄漏端点的逐 qid Top-5 选择一致性结果见表 8。

表 8 六个泄漏端点的逐 qid 选择一致性

端点	目标条件	Top-5 不同 qid	状态
query-only,0	D3	0/200	PASS
query-only,1	D2	0/200	PASS
evidence-only,0	D3	0/200	PASS
evidence-only,1	D1	0/200	PASS
joint,0	D3	0/200	PASS
joint,1	D0	0/200	PASS

三类泄漏场景下 DemandCov@5 与 NDCG@10 随泄漏率变化的均值及经验区间如图 2 所示。




图 2 三类标签泄漏下 DemandCov 与 NDCG 的均值及经验区间

六个确定性端点在逐 qid Top-5 层面全部闭合, 1050 行 DemandCov 重放无不一致。query-only 由 D3 过渡至 D2 时, DemandCov 由 0.8745 降至 0.8702, NDCG 由 0.6293 升至 0.6319; evidence-only 过渡至 D1 时分别变为 0.9219 和 0.6065; joint 过渡至 D0 时分别变为 0.9398 和 0.6012。中间比例存在 seed 波动, 低泄漏区间亦非严格单调。结果提示, 在 formal_train 严格 OOF 敏感性分析中, 证据侧 Gold 暴露对覆盖的响应更明显, 同时伴随相关性排序下降; 该趋势尚未在保留划分上独立复现。

4.4 生成端 Faithfulness 与效用

四种证据条件下生成端人工评价指标的均值见表

9。

表 9 四条件生成端人工评价均值(n=60)

条件	Faith	Comp	Util	Unsup	Risk
B0	1.917	1.817	1.733	0.033	0.017
D0	1.933	1.800	1.767	0.033	0.017
D3-TFIDF	1.967	1.867	1.850	0.033	0.000
D3-E2-R	1.900	1.850	1.767	0.083	0.033

注：Faith.=Faithfulness；Comp.=Demand completeness；Unsup.=Unsupported claim；Risk=Critical risk omission。各条件相对 B0 的关键配对统计结果见表 10。

表 10 生成端关键配对统计

比较	均值差	95% CI	p_raw	p_Holm
D0-B0/F	0.0167	[-.050,.083]	1.0000	1.0000
D0-B0/U	0.0333	[-.050,.117]	0.6875	1.0000
D3-TFIDF-B0/F	0.0500	[-.017,.117]	0.3750	1.0000
D3-TFIDF-B0/U	0.1167	[.033,.217]	0.0391	0.7812
D3-E2-R-B0/U	0.0333	[-.050,.133]	0.7266	1.0000

四条件 Friedman 全局检验均未达到显著水平：Faithfulness、需求完整度、总体效用、Unsupported claim 和 Critical risk omission 的 p 值分别为 0.3357、0.2322、0.0585、0.1899 和 0.4936；Answer relevance 因方差为 0 不检验。预先定义的配对比较继续使用 Holm 方法控制家族错误率。D0 相较 B0 的 Faithfulness 与总体效用均不显著；D3-TFIDF 总体效用表现为 8 题提高、1 题降低、51 题持平，原始 $p=0.0391$ ，Holm 校正后 $p=0.7812$ ，只能作为探索性描述，不能宣称统计优势。

D3-E2-RoBERTa 与 D3-TFIDF 的聚合 DemandCov 接近，但 60 题中仅 11 题 Top-5 集合完全相同，49 题至少替换 1 篇证据，平均 Jaccard 为 0.6266。其 Unsupported claim 为 0.0833 (5/60)，高于 B0 的 0.0333 (2/60)；Critical risk omission 为 0.0333 (2/60)，高于 B0 的 0.0167 (1/60)。事件稀疏且检验不显著，不能据此归因于 RoBERTa 或作安全性因果判断。

4.5 MMR 基线与 Top-K 敏感性

MMR-TFIDF、B0 与 D3-TFIDF 在 K=5 时的三个划分主结果见表 11。

表 11 MMR-TFIDF 代理基线的 K=5 主结果

划分	方法	DemandCov@5/ND CG@10
formal	B0	0.8762/0.6413
formal	MMR-TFIDF	0.8768/0.6294
formal	D3-TFIDF	0.8745/0.6293
internal	B0	0.9183/0.5338
internal	MMR-TFIDF	0.9310/0.5180
internal	D3-TFIDF	0.9216/0.5075
external	B0	0.9630/0.5166
external	MMR-TFIDF	0.9589/0.5011
external	D3-TFIDF	0.9730/0.4954

λ 仅在 formal_dev 选择并冻结为 0.6。MMR-TFIDF 相对 B0 的 DemandCov@5 差值在 formal、internal 和 external 分别为 0.0005、0.0128 和 -0.0041，Holm 校正后均不显著；相对 D3-TFIDF 的覆盖差异亦均不显著。MMR-TFIDF 的 NDCG@10 均低于 B0，其中 external 差异经 Holm 校正后显著 ($\Delta=-0.0155$, $p=0.0066$)。因此，一般多样化与当前需求感知选择均未形成稳定覆盖增益，且集合去冗余可能伴随相关性排序代价。为检验上述现象是否依赖单一证据预算，进一步比较 K=3、5、7 时的 DemandCov@K 与 NDCG@K，结果见表 12。

表 12 K=3、5、7 下的 DemandCov@K/NDCG@K

划分/方法	K=3 → K=5 DC/NDCG@K	K=7 DC/NDCG @7
formal/B0	0.8114/0.8978 → 0.8762/0.8998	0.9113/0.90 48
formal/MMR	0.8303/0.8890 → 0.8768/0.8847	0.9216/0.89 62
formal/D3	0.8274/0.8898 → 0.8745/0.8861	0.9016/0.89 29
internal/B0	0.8715/0.6635 → 0.9183/0.6911	0.9319/0.71 61
internal/MMR	0.8738/0.6600 → 0.9310/0.6725	0.9455/0.70 28
internal/D3	0.8653/0.6391 → 0.9216/0.6595	0.9399/0.68 76
external/B0	0.9137/0.6892 → 0.9630/0.6956	0.9707/0.71 26
external/MMR	0.9020/0.6614 → 0.9589/0.6760	0.9742/0.70 90
external/D3	0.9454/0.6520 → 0.9730/0.6660	0.9812/0.69 72

仅改变证据预算 K 后，三个划分中各方法的 DemandCov@K 均随 K 增加。formal 和 internal 中 MMR-TFIDF 在三个 K 值下均保持最高或并列最高覆

盖, external 则由 D3-TFIDF 保持最高覆盖; 方法最大排名位移不超过 1, 主要方向具有描述性稳定性。D05 照护与急症在 $K=3$ 时最易遗漏, 且随 K 增加的覆盖增幅最大。该结果说明观察到的覆盖—排序权衡并非 $K=5$ 单点现象, 但“方向稳定”不代表方法差异显著或等效。

4.6 生成子集的结构审计与可辨识度限制

为分析生成子集中检索变化的可辨识度及 B0—D0 证据集合差异, 开展证据结构审计, 结果见表 13。

表 13 生成子集的检索变化与证据结构审计($n=60$)

审计项	结果与 95% CI	解释边界
D3—B0 Δ DemandCov 持平	59/60 题(98.3%)	相关自变量几乎无变异
B0 与 D0 集合 相同/Jaccard	14/60 题; 0.6562 [0.5996,0.7139]	D0 造成中等程度重组
平均替换文档 数	1.1500 [0.9500,1.3667]	每题约替换 1 篇证据
文本质心相似 度	0.8211 [0.7870,0.8541]	整体语义上下文仍较接近
集合冗余差(D0 —B0)	-0.0013 [- 0.0109,0.0094]	未见稳定冗余变化

D3-TFIDF 相对 B0 仅 1 题的 DemandCov 提高, 59 题持平, 因此 Kendall 与 Spearman 相关系数缺乏足够辨识度, 不能据此推断覆盖与生成质量无关。B0—D0 结构审计显示, Oracle 条件在 46/60 题中替换证据, 平均替换 1.15 篇, 但文本质心相似度仍为 0.8211, 集合冗余差的置信区间跨 0。换言之, D0 确实改变了部分证据构成, 却未使上下文整体发生剧烈变化, 这为生成评分差异不显著提供了另一种解释。该审计仅作文本结构描述, 不作需求类别层面的因果解释。

4.7 统计功效与可检测效应

当前样本量下的统计功效、最小可检测效应及达到 80%功效所需样本量见表 14。

表 14 当前样本的功效与最小可检测效应

场景	n	Δ	Power	MDE	n80
formal	200	-0.0017	0.05	0.0248	≈ 42300
internal	200	0.0033	0.07	0.0228	≈ 9430
external	142	0.0100	0.18	0.0274	≈ 1055
Utility	60	0.1167	0.67	0.1332	≈ 82

注: formal、internal 和 external 均为 D3—B0; 由配对 Bootstrap 区间估计标准误并作正态近似。MDE 为 $\alpha=0.05$ 、power=0.80 时的最小可检测均值差, 仅用

于样本敏感性解释^[23]。

检索端 D3 的观察差远低于当前样本的 80%最小可检测差, 故“不显著”不能解释为严格等效; 但若保持同一微小效应, 估算所需样本约为 1055 至 4.23 万题, 也说明其实际增益可能有限。生成总体效用近似功效为 0.67, 达到常规 80%功效约需 82 题; 考虑 Holm 校正和高持平率, 实际需要更大样本。

5 讨论

5.1 Oracle 有效为何不等于部署有效

OracleGain 说明候选池中存在能够覆盖更多需求的文档组合, 但部署时必须同时预测“问题需要什么”和“证据支持什么”。Query 需求通常可由显式问法识别; Evidence 支持则是 Query—Document 关系判断, 涉及否定、条件、适用人群和语义蕴含。低资源 TF-IDF+LR 难以充分建模这些关系, 因此在当前配置中 EvidenceLoss 持续大于 QueryLoss。这一诊断不适用于完整微调的预训练模型、LLM 分类器或 Q1/E2 联合模型。

5.2 覆盖、排序与生成的目标张力

D0 和 D1 多次出现 DemandCov 提高而 NDCG 下降, 说明需求覆盖与相关性排序存在直接目标张力。MMR-TFIDF 平均替换 1.0~1.4 篇证据, 并明显降低文档内部相似度, 但其 DemandCov@5 相对 B0 和 D3 均无稳定显著差异; D3 与 MMR 在覆盖维度难以区分, 而两者均可能付出排序代价。 $K=3$ 、5、7 下主要方法排序方向一致, 说明上述现象不完全由 Top-5 单点设定造成。表 13 进一步表明, D3—B0 在生成子集中的覆盖差值有 59/60 题持平, 当前数据无法有效估计覆盖变化与人工评分变化的相关关系; B0—D0 虽平均替换 1.15 篇证据, 但集合 Jaccard 为 0.6562、文本质心相似度为 0.8211, 说明 Oracle 条件造成的是局部证据重组而非上下文整体改写。因此, 更准确的结论是: 在本实验条件下, DemandCov 改善未稳定反映在所选人工评价维度上, 而不能外推为“检索差异一般不会影响生成”。

5.3 负结果、天花板效应与结论边界

若只报告 D0, Oracle 空间容易被误写为算法收益; 若只报告 D3, 又可能把低功效下的不显著结果简单解释为无效。B0—D3 分解表明, 候选池存在额外覆盖空间, 但当前预测配置未稳定恢复。另一方面, 240/240 条 Answer relevance 均为满分, Faithfulness 也接近量表上限, 生成端区分度受到天花板效应压缩。

本文因此把结果限定为“当前配置下未观察到稳健优势”, 不将其视为等效性证明。

5.4 从诊断结果到工程改进路径

现有结果提示三条工程路径: 一是将 E2 升级为中文医疗 Cross-Encoder 或多标签蕴含模型, 并在低置信样本上回退 B0; 二是在开发集上联合约束 DemandCov 与 NDCG; 三是根据需求数量和风险类别自适应分配 Top-K。系统仍应固定 Public/Private 字段边界, 避免评价标签进入推理接口^[24]。xQuAD、Query2doc、HyDE 和 Self-RAG 可作为后续候选增强与按需检索方案^{[25][26][27][28]}, 但尚未在本文中验证。

5.5 局限性与外部有效性

本研究的检索划分为 200、200 和 142 个 qid, 生成盲评为 60 个 qid, 统计功效仍受独立 qid 数量限制, 负结果不构成等效性证明。D3-E2-RoBERTa 仅升级 E2, MMR 采用字符 TF-IDF 相似度, 均不能代表更强模型的性能上限。6 类需求、K=3/5/7、候选池规模和提示词设置亦限制结论外推。生成评价存在天花板效应, 且标注团队不含执业医师; 泄漏注入仅在 formal_train OOF 中开展。因此, 可迁移的是字段隔离和组件诊断思路, 而非当前方法的绝对性能。

6 结 语

围绕医疗 RAG 中私有状态标签泄漏与 Oracle—部署混用问题, 本文形成了由 Public/Private 隔离、B0—D3 条件分解、渐进泄漏注入、MMR 对照、Top-K 敏感性、生成盲评及证据结构审计组成的无泄漏评测流程。双 Oracle 条件显示候选池存在额外需求覆盖空间, 但当前低资源 D3 未形成稳定覆盖优势, 并在部分划分降低 NDCG; MMR-TFIDF 与 D3 在覆盖维度无稳定差异, 说明一般多样化与需求感知信号的额外收益尚难区分。K=3、5、7 下主要方向一致; 生成端比较经多重校正后未形成稳健优势, 而结构审计显示 D0 主要造成局部证据重组。在相同数据边界和标注条件下, 该流程可帮助定位应优先改进证据关系建模、覆盖—排序联合目标还是证据预算配置。研究结果仅支持类似配置下的诊断性解释: 联合报告 Gold 边界、诊断条件、通用多样化基线、证据预算、覆盖、排序、生成指标和可检测效应范围, 可能有助于减少把 Oracle 空间、集合变化或描述性均值误解为可部署收益的风险。

数据与代码可用性说明

已整理最小结果复算与一致性验证材料, 包含三

划分脱敏逐 qid 选择结果、B0—D3 主结果、Oracle—部署差距分解、配对统计、Gold 边界检查、泄漏逐 seed 结果、生成端人工评分及 SHA256 清单。生成衔接与结构审计材料包括 d3_b0_retrieval_generation_per_qid.csv、retrieval_generation_correlation.csv、b0_d0_evidence_structure_per_qid.csv 和 generation_friedman_test.csv; 新增 MMR 与 Top-K 材料包括 mmr_dev_lambda_selection.csv、mmr_summary.csv、mmr_paired_bootstrap.csv、topk_sensitivity_summary.csv 和 topk_demand_category_coverage.csv。受许可限制, 完整问题文本、候选文档、模型权重和私有 Gold 不公开; 不能独立核验的运行参数不作推断性补写。

参考文献

- [1] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems 33. Red Hook, NY: Curran Associates, 2020: 9459-9474.
- [2] XIONG G, JIN Q, LU Z, et al. Benchmarking retrieval-augmented generation for medicine[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok, Thailand: Association for Computational Linguistics, 2024: 6233-6251.
- [3] PARK C, MOON H, PARK C, et al. MIRAGE: A metric-intensive benchmark for retrieval-augmented generation evaluation[C]//Findings of the Association for Computational Linguistics: NAACL 2025. Albuquerque, New Mexico: Association for Computational Linguistics, 2025: 2883-2900.
- [4] XIE K, LABAN P, CHOUBEY P K, et al. Do RAG systems cover what matters? Evaluating and optimizing responses with sub-question coverage[C]//Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies. Albuquerque, New Mexico: Association for Computational Linguistics, 2025: 5836-5849.
- [5] SOHN J, PARK Y, YOON C, et al. Rationale-guided retrieval augmented generation for medical question answering[C]//Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies. Albuquerque, New Mexico: Association for Computational Linguistics, 2025: 12739-12753.
- [6] KAPOOR S, NARAYANAN A. Leakage and the reproducibility crisis in machine-learning-based science[J]. Patterns, 2023, 4(9): 100804.
- [7] ES S, JAMES J, ESPINOSA ANKE L, et al. RAGAs: Automated evaluation of retrieval augmented generation[C]//Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations. St. Julian's, Malta: Association for Computational Linguistics, 2024: 150-158.
- [8] SAAD-FALCON J, KHATTAB O, POTTS C, et al. ARES: An automated evaluation framework for retrieval-augmented generation systems[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Mexico City, Mexico: Association for Computational Linguistics, 2024: 338-354.

- [9] RU D, QIU L, HU X, et al. RAGChecker: A fine-grained framework for diagnosing retrieval-augmented generation[C]//Advances in Neural Information Processing Systems 37. Red Hook, NY: Curran Associates, 2024: 21999-22027.
- [10] NIU C, WU Y, ZHU J, et al. RAGTruth: A hallucination corpus for developing trustworthy retrieval-augmented language models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics. Bangkok, Thailand: Association for Computational Linguistics, 2024: 10862-10878.
- [11] CHEN J, LIN H, HAN X, et al. Benchmarking large language models in retrieval-augmented generation[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(16): 17754-17762.
- [12] ROBERTSON S, ZARAGOZA H. The probabilistic relevance framework: BM25 and beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333-389.
- [13] KARPUKHIN V, OĞUZ B, MIN S, et al. Dense passage retrieval for open-domain question answering[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Online: Association for Computational Linguistics, 2020: 6769-6781.
- [14] CORMACK G V, CLARKE C L A, BÜTTCHER S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods[C]//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2009: 758-759.
- [15] REIMERS N, GUREVYCH I. Sentence-BERT: Sentence embeddings using Siamese BERT-networks[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong, China: Association for Computational Linguistics, 2019: 3982-3992.
- [16] CARBONELL J, GOLDSTEIN J. The use of MMR, diversity-based reranking for reordering documents and producing summaries[C]//Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 1998: 335-336.
- [17] 田萱, 吴志超. 基于信息检索的知识库问答综述[J]. 计算机研究与发展, 2025, 62(2): 314-335.
- [18] 毕枫林, 张豈明, 张嘉睿, 等. 基于滑动窗口策略的大语言模型检索增强生成系统[J]. 计算机研究与发展, 2025, 62(7): 1597-1610.
- [19] HE J, FU M, TU M. Applying deep matching networks to Chinese medical question answering: A study and a dataset[J]. BMC Medical Informatics and Decision Making, 2019, 19(Suppl 2): 52.
- [20] ZHANG S, ZHANG X, WANG H, et al. Multi-scale attentive interaction networks for Chinese medical question answer selection[J]. IEEE Access, 2018, 6: 74061-74071.
- [21] JÄRVELIN K, KEKÄLÄINEN J. Cumulated gain-based evaluation of IR techniques[J]. ACM Transactions on Information Systems, 2002, 20(4): 422-446.
- [22] EFRON B, TIBSHIRANI R J. An introduction to the bootstrap[M]. New York: Chapman & Hall, 1993.
- [23] LAKENS D. Sample size justification[J]. Collabra: Psychology, 2022, 8(1): 33267.
- [24] KAUFMAN S, ROSSET S, PERLICH C, et al. Leakage in data mining: Formulation, detection, and avoidance[J]. ACM Transactions on Knowledge Discovery from Data, 2012, 6(4): 15:1-15:21.
- [25] SANTOS R L T, MACDONALD C, OUNIS I. Exploiting query reformulations for web search result diversification[C]//Proceedings of the 19th International Conference on World Wide Web. New York: ACM, 2010: 881-890.
- [26] WANG L, YANG N, WEI F. Query2doc: Query expansion with large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9414-9423.
- [27] GAO L, MA X, LIN J, et al. Precise zero-shot dense retrieval without relevance labels[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Toronto, Canada: Association for Computational Linguistics, 2023: 1762-1777.
- [28] ASAI A, WU Z, WANG Y, et al. Self-RAG: Learning to retrieve, generate, and critique through self-reflection[C]//The Twelfth International Conference on Learning Representations. 2024.

作者简介

史语涵

- 学位:本科在读
- 主研领域:自然语言处理、检索增强生成、医学信息系统
- 身份证号:141122200608120062
- 手机号:15935846627
- 单位:太原理工大学软件学院
- 通信地址:山西省晋中市榆次区高校新区太原理工大学明向校区
- 邮政编码:030600
- E-mail: 15935846627@163.com

王琦(通讯作者)

- 职称:讲师
- 主研领域:脑机接口，情感计算
- 身份证号:140121199607102521
- 手机号:13485342029
- 单位:太原理工大学软件学院
- 通信地址:山西省晋中市榆次区高校新区太原理工大学明向校区
- 邮政编码:030600
- E-mail:wangqi05@tyut.edu.cn